การทดสอบสกัดข้อความออกจากไฟล์เอกสาร PDF

ข้อมูลที่สำคัญจากการใช้งาน RAG มาจากไฟล์เอกสารที่มีข้อมูลต่างๆ ที่ต้องการให้ LLM สามารถเข้ามาค้นหาได้ โดยเอกสารที่นำเข้าระบบหากเป็นไฟล์ PDF จะต้องถูกนำมาสกัดข้อมูลไม่ว่าข้อมูลใน PDF จากเป็นข้อความที่สามารถสกัดได้โดยตรง หรือว่าเป็นข้อความที่เป็นภาพก็ควรจะใช้ OCR ในการสกัดเฉพาะส่วนที่เป็นข้อความออกมา

การทดสอบวิธีการสกัดข้อมูลที่เป็นข้อความออกจากไฟล์ PDF จึงมีความจำเป็นมากโดยเฉพาะกับภาษาไทยที่อาจจะยังมี Model หรือ Library ที่รองรับไม่เยอะมากนัก การที่สกัดข้อมูลไม่ถูกต้องหรือ มีความแม่นยำน้อย จะทำให้ RAG ไม่สามารถดึงข้อมูลสำคัญเข้ามาช่วยในการตอบได้ ส่วนนี้เป็นการทดสอบทั้งแบบเอกสารที่เป็น 1 คอลัมน์ และเอกสารที่เป็น 2 คอลัมน์ รวมถึงจะมีการทดสอบความสามารถในการแปลตาราง และสมการทางคณิตศาสตร์.

Yes, This is the PDF text extraction test document. We hope that the library can extract it right both Thai and English texts. That's our goal of this test.

ทดสอบการอ่านข้อมูลจากตาราง

วิธีที่ 1	วิธีที่ 2	วิธีที่ 3	วิธีที่ 4
เร็ว	**ช้า**	**ปานกลาง**	**ไม่สามารถใช้งานได้**
แม่นยำ	**ไม่แม่นยำ**	**ปานกลาง**	*N/A*

- **ทดสอบการใช้สมการ 1 :** $A = \pi r^2$
- **ทดสอบการใช้สมการ 2:** $(1+x)^n = 1 + \frac{nx}{1!} + \frac{n(n-1)x^2}{2!} + \cdots$
- **ทดสอบสัญลักษณ์ :** € ∞ £ ≤ ≥

เป็นมนุษย์สุดประเสริฐเลิศคุณค่า ควรฝึกหัดตนให้มีจิตใจเมตตา ช่วยเหลือเกื้อกูลผู้อื่นตามวิสัย รู้รักสามัคคีไม่เบียดเบียนกัน มีสติรอบคอบในทุกกิจการ ไม่หลงลืมหน้าที่ของตนเอง ทั้งยังเพียรพยายามพัฒนาความรู้ให้ทันโลกยุคใหม่ เพื่อสร้างประโยชน์สุขแก่สังคมและส่วนรวมอย่างมั่นคงยั่งยืน

ในโลกยุคดิจิทัลที่เปลี่ยนแปลงอย่างรวดเร็ว มนุษย์ผู้มีปัญญาควรเรียนรู้และปรับตัวอยู่เสมอ การมีน้ำใจไมตรีช่วยเหลือกันตามวิสัยเป็นสิ่งสำคัญไม่แพ้ความรู้ความสามารถ การร่วมแรงร่วมใจกันด้วยความจริงใจทำให้สังคมสงบสุขและเจริญก้าวหน้า ผู้ที่ตระหนักถึงหน้าที่ของตน ยึดมั่นในความรับผิดชอบ และพัฒนาตนอย่างต่อเนื่อง ย่อมเป็นกำลังสำคัญที่ทำให้บ้านเมืองมั่นคง ทั้งยังสร้างแรงบันดาลใจให้ผู้อื่นทำความดีด้วยหัวใจบริสุทธิ์

========== THE END ==========

การทดสอบสกัดข้อความออกจากไฟล์เอกสาร PDF

ข้อมูลที่สำคัญจากการใช้งาน RAG มาจากไฟล์เอกสารที่มีข้อมูลต่างๆ ที่ต้องการให้ LLM สามารถเข้ามาค้นหาได้ โดยเอกสารที่นำเข้าระบบหากเป็นไฟล์ PDF จะต้องถูกนำมาสกัดข้อมูลไม่ว่าข้อมูลใน PDF จากเป็นข้อความที่สามารถสกัดได้โดยตรง หรือว่าเป็นข้อความที่เป็นภาพก็ควรจะใช้ OCR ในการสกัดเฉพาะส่วนที่เป็นข้อความออกมา

การทดสอบวิธีการสกัดข้อมูลที่เป็นข้อความออกจากไฟล์ PDF จึงมีความจำเป็นมากโดยเฉพาะกับภาษาไทยที่อาจจะยังมี Model หรือ Library ที่รองรับไม่เยอะมากนัก การที่สกัดข้อมูลไม่ถูกต้องหรือ มีความแม่นยำน้อย จะทำให้ RAG ไม่สามารถดึงข้อมูลสำคัญเข้ามาช่วยในการตอบได้ ส่วนนี้เป็นการทดสอบทั้งแบบเอกสารที่เป็น 1 คอลัมน์ และเอกสารที่เป็น 2 คอลัมน์ รวมถึงจะมีการทดสอบความสามารถในการแปลตาราง และสมการทางคณิตศาสตร์.

Yes, This is the PDF text extraction test document. We hope that the library can extract it right both Thai and English texts. That's our goal of this test.

ทดสอบการอ่านข้อมูลจากตาราง

วิธีที่ 1	วิธีที่ 2	วิธีที่ 3	วิธีที่ 4
เร็ว	ช้า	ปานกลาง	ไม่สามารถใช้งานได้
แม่นยำ	ไม่แม่นยำ	ปานกลาง	N/A

- **ทดสอบการใช้สมการ 1 :** $A = \pi r^2$
- **ทดสอบการใช้สมการ 2:** $(1+x)^n = 1 + \frac{nx}{1!} + \frac{n(n-1)x^2}{2!} + \cdots$
- **ทดสอบสัญลักษณ์ :** € ∞ £ ≤ ≥

เป็นมนุษย์สุดประเสริฐเลิศคุณค่า ควรฝึกหัดตนให้มีจิตใจเมตตา ช่วยเหลือเกื้อกูลผู้อื่นตามวิสัย รู้รักสามัคคีไม่เบียดเบียนกัน มีสติรอบคอบในทุกกิจการ ไม่หลงลืมหน้าที่ของตนเอง ทั้งยังเพียรพยายามพัฒนาความรู้ให้ทันโลกยุคใหม่ เพื่อสร้างประโยชน์สุขแก่สังคมและส่วนรวมอย่างมั่นคงยั่งยืน

ในโลกยุคดิจิทัลที่เปลี่ยนแปลงอย่างรวดเร็ว มนุษย์ผู้มีปัญญาควรเรียนรู้และปรับตัวอยู่เสมอ การมีน้ำใจไมตรีช่วยเหลือกันตามวิสัยเป็นสิ่งสำคัญไม่แพ้ความรู้ความสามารถ การร่วมแรงร่วมใจกันด้วยความจริงใจทำให้สังคมสงบสุขและเจริญก้าวหน้า ผู้ที่ตระหนักถึงหน้าที่ของตน ยึดมั่นในความรับผิดชอบ และพัฒนาตนอย่างต่อเนื่อง ย่อมเป็นกำลังสำคัญที่ทำให้บ้านเมืองมั่นคง ทั้งยังสร้างแรงบันดาลใจให้ผู้อื่นทำความดีด้วยหัวใจบริสุทธิ์

========== THE END ==========